

Réseaux de Neurones Convolutifs (CNN)

De la vision biologique aux architectures modernes

Votre Nom

30 avril 2026

Département Informatique / IA

1. Introduction et Historique
2. Mécanismes Mathématiques
3. Réduction de dimension : Le Pooling
4. Architectures de Référence
5. L'efficacité par la profondeur : VGG
6. L'efficacité par la profondeur : VGG
7. Innovations et Performance
8. Applications et Pratique

Introduction et Historique

Pourquoi la Convolution ?

Le problème des réseaux denses (MLP) sur les images :

- **Explosion des paramètres** : Une image 1000×1000 vers une couche de 1000 neurones = 10^9 poids.
- **Perte de topologie** : L'aplatissement (flattening) détruit la proximité des pixels.
- **Invariance par translation** : Un MLP ne reconnaît pas un objet s'il est légèrement déplacé.


La philosophie CNN

Apprendre des filtres locaux capables d'extraire des motifs (bords, textures) peu importe leur position.

Inspiration Biologique (Hubel & Wiesel, 1962)

L'étude du cortex visuel du chat a révélé :

- **Champs récepteurs locaux** : Les neurones ne répondent qu'à une petite zone de l'image.
- **Cellules Simples** : Détectent les orientations (lignes).
- **Cellules Complexes** : Gèrent l'invariance (mouvement).



1980 : Neocognitron Premier modèle hiérarchique (Fukushima).

1998 : LeNet-5 Premier succès industriel (Yann LeCun) pour MNIST.


2012 : AlexNet Révolution du Deep Learning (ImageNet).

2015 : ResNet Réseaux ultra-profonds (150+ couches).

Le Neocognitron (1980)

Kunihiko Fukushima propose une architecture capable de reconnaître des caractères malgré les distorsions.

- Utilise des couches alternées (S-cells et C-cells).
- Problème : Pas de rétropropagation (Backprop) pour l'entraînement global.
- Pose les bases de la hiérarchie visuelle.




La Naissance du CNN Moderne

De la reconnaissance de chiffres à la vision universelle

LeNet-5 : Le premier succès (1998)

Développé par Yann LeCun aux laboratoires Bell pour lire les codes postaux et les chèques.

- Combinaison : Convolution + Pooling + MLP.
- Entraîné par Backpropagation.
- Démontre l'efficacité sur le dataset MNIST.




15.3%

Taux d'erreur Top-5

AlexNet gagne la compétition ImageNet en battant les méthodes classiques par une marge immense (le second était à 26%).


Clés du succès : GPUs, fonction ReLU, et Dropout.





Vers la Profondeur

Après 2012, les réseaux deviennent de plus en plus profonds pour capturer des abstractions complexes.

ResNet (2015) : Introduit les connexions résiduelles pour résoudre le problème de l'évanouissement du gradient.



Applications d'aujourd'hui




- Véhicules autonomes : Détection de piétons et panneaux.
- Imagerie Médicale : Diagnostic précoce de cancers.
- Surveillance : Reconnaissance faciale en temps réel.
- Génération d'images : GANs et Diffusion Models (utilisant des convolutions).

Mécanismes Mathématiques

Le Noyau (Kernel)

Le noyau est une petite matrice de poids (souvent 3x3 ou 5x5) qui "glisse" sur l'image.

- Il extrait des caractéristiques spécifiques (bords, coins).
- Les poids sont appris par le réseau durant l'entraînement.
- Un noyau de taille $K \times K$ réduit naturellement la taille de la sortie.



L'Opération de Convolution

Un noyau (matrice K) glisse sur l'image I . La valeur de sortie en (i, j) est :

$$S(i, j) = (I * K)(i, j) = \sum_{m=0}^{k-1} \sum_{n=0}^{k-1} I(i + m, j + n) K(m, n)$$




Note : En deep learning, on effectue techniquement une corrélation croisée.

Le padding

Le Padding consiste à ajouter une bordure de pixels (souvent des zéros) autour de l'image.


- Garder la dimension : Évite que l'image ne rétrécisse à chaque couche.
- Bordures : Permet au noyau de traiter les pixels du bord autant que ceux du centre.
- Valid Padding : Pas de padding (réduction).
- Same Padding : Sortie identique à l'entrée.



Le Stride (le pas)

Le Stride définit de combien de pixels le noyau se déplace à chaque étape.

- Stride 1 : Déplacement pixel par pixel (standard).
- Stride 2+ : Saute des pixels, ce qui réduit drastiquement la résolution de la sortie.
- Utilisé pour réduire la charge de calcul et augmenter le champ récepteur.



Hyperparamètres : Padding et Stride

- **Padding (P)** : Ajout de pixels (zéros) pour éviter le rétrécissement de l'image.
- **Stride (S)** : Pas du noyau (ex : Stride 2 saute un pixel sur deux).

Dimension de sortie

Pour une entrée de taille W , noyau K :

$$W_{out} = \left\lfloor \frac{W - K + 2P}{S} \right\rfloor + 1$$



Réduction de dimension : Le Pooling

Le Pooling (Sous-échantillonnage)

Réduire la taille spatiale pour l'invariance et la mémoire.

Max Pooling : Garde la valeur la plus forte (détection de motifs).


Average Pooling : Fait la moyenne (lissage).



Convolutions 3D (Canaux)

Pour une image RGB, le noyau est également en 3D (ex : $3 \times 3 \times 3$).

- On effectue la convolution sur chaque canal (R, G, B) simultanément.
- Les résultats sont sommés pour produire une seule carte de caractéristiques (Feature Map) par filtre.
- Si on utilise 64 filtres, la sortie aura 64 canaux.



Paramètres de convolution


Paramètre	Impact sur la sortie	Usage courant
Taille de Noyau (K)	Plus K est grand, plus la sortie est petite.	3x3 ou 5x5
Stride (S)	Réduit la dimension par un facteur S.	1 (interne), 2 (réduction)
Padding (P)	Augmente la dimension de la sortie.	"Same" pour conserver W
Pooling	Réduit drastiquement la dimension spatiale.	2x2 avec Stride 2

Architectures de Référence

LeNet-5 (1998) : L'origine


Le premier réseau convolutif "moderne" pour la lecture de chiffres (MNIST).

- Structure : 2 couches Conv + 3 couches FC.
- Paramètres : Environ 60 000.
- Innovation : Utilisation de la pooling moyenne (Average Pooling) et de l'activation Tanh.



AlexNet (2012) : La révolution


- Utilisation des GPU (60 000 000 de paramètres)
- Fonction ReLu remplace Tanh pour un entraînement 6x plus rapide sans saturation du gradient.



L'efficacité par la profondeur : VGG


VGG-16 (2014)

- **Principe** : Utiliser exclusivement des petits filtres 3×3 .
- **Avantage** : Deux couches 3×3 ont le même champ récepteur qu'une couche 5×5 mais avec moins de paramètres et plus de non-linéarité.
- **Défaut** : Très gourmand en mémoire (138 millions de paramètres).



L'efficacité par la profondeur : VGG

VGG-16 (2014)




Innovations et Performance

Inception/GoogleNet

L'idée : Pourquoi choisir une taille de filtre ? Utilisons-les toutes en parallèle !


- Modules Inception : Convolutions 1x1, 3x3, 5x5 dans le même bloc.
- Gains : 22 couches mais 10x moins de paramètres qu'AlexNet (6M).
- Utilise des convolutions 1x1 pour réduire la dimensionnalité.



ResNet (2015) : Le "Skip"

Le gagnant qui a permis de dépasser les 100 couches.

- Skip Connections : Le signal "saute" des couches pour préserver l'information.
- Solution : Résout l'évanouissement du gradient (Vanishing Gradient).
- Permet d'entraîner des réseaux de 152 couches et plus.



Comparaison de modèles CNN


Modèle (Année)	Top-5 Error	Couches	Innovation Clé
AlexNet (2012)	15.3%	8	GPU, ReLU, Dropout
VGG-16 (2014)	7.3%	16	Filtres 3x3 uniformes
GoogLeNet (2014)	6.7%	22	Modules Inception
ResNet-152 (2015)	3.6%	152	Connexions Résiduelles

Vers l'Efficacité (EfficientNet)

Aujourd'hui, on ne cherche plus seulement la profondeur, mais le ratio optimal entre :

- Profondeur (Nombre de couches).
- Largeur (Nombre de canaux).
- Résolution (Taille de l'image).

EfficientNet équilibre ces trois dimensions pour des performances maximales avec un coût minimal.



Applications et Pratique

- **Détection d'objets (YOLO)** : Bounding boxes sur les objets.
- **Segmentation Sémantique** : Prédire la classe de chaque pixel.
- **Génération d'images** : Utilisation de convolutions "transposées".

Comment entraîner un modèle performant avec seulement 100 images ?

1. Charger un modèle pré-entraîné sur **ImageNet** (ex : ResNet50).
2. **Freezing** : Geler les poids des couches de convolution.
3. **Fine-tuning** : Remplacer le classifieur final et l'entraîner sur vos données spécifiques.


Pourquoi ça marche ?

Les premières couches apprennent des formes universelles (lignes, points) communes à toutes les images.

Cas d'usage : Imagerie Médicale

Détection de Pathologies Un modèle entraîné sur des chiens et chats (ImageNet) peut être "ajusté" pour détecter des tumeurs sur des radios X.

- Gain de temps : Quelques heures suffisent.
- Précision : Souvent supérieure à un entraînement "from scratch".
- Petit Dataset : Fonctionne avec seulement 500 images.



PyTorch / TensorFlow

Les deux piliers pour construire et entraîner des CNN de manière professionnelle.

Hugging Face

La plateforme de référence pour télécharger des modèles pré-entraînés en un clic.

”

L'IA n'est plus une question d'algorithmes complexes, mais de gestion de données et d'ajustement de modèles existants.”

Merci de votre attention !
Questions ?